

Resumo resultados - Early Stopping VDB

Erich Johann Costa de Carvalho^a, Maria Vitória da Silva Vieira^a and Matheus de Souza Figueiredo^a

^aCEFET-RJ / Maracanã

1. CONTEXTO

No treinamento de redes neurais, o early stopping tradicional utiliza uma partição fixa de validação para evitar o tanto o overfitting quanto o underfitting, parando o modelo no momento certo, o mínimo da curva de validação. Mas essa abordagem tem a limitação de deixar a decisão de parada totalmente dependente de uma única divisão dos dados. Como alternativa, a validação dinâmica reamostra esses conjuntos a cada época para aproveitar melhor o dataset, porém essa frequência introduz um alto ruído na curva de loss, tornando o critério de interrupção instável.

Para mitigar esse problema, este estudo investiga uma abordagem intermediária: o Early Stopping com Validação Dinâmica em Blocos. A técnica consiste em congelar as partições de treino e validação por um bloco de X épocas antes de realizar uma nova reamostragem de dados.

2. METODOLOGIA EXPERIMENTAL

O conjunto de dados escolhido consiste em um para regressão e outro para classificação. O primeiro usa o dataset Student, com variável alvo "G3". Foram aplicadas normalização one hot encoding nas variáveis categóricas e min-max scaler no conjunto de treinamento. O segundo dataset é o Titanic, com variável alvo "Class", nesse dataset foram selecionadas as colunas ["Pclass", "Age", "SibSp", "Parch", "Fare"] para predição, removendo qualquer linha que tenha NA. Também sofrendo normalização min-max nos dados de treinamento. Antes do pré processamento os dados foram separados em teste e treino, com o teste sendo usado somente no final para avaliação dos modelos.

Para a modelagem de ambos os problemas, utilizou-se uma rede neural artificial do tipo *Multi-Layer Perceptron* (MLP) da biblioteca *daltoolboxdp*. A tabela 1 contém os hiperparâmetros gerais usados nos modelos.

Table 1. Hiperparâmetros gerais da rede MLP.

Hiperparâmetro	Valor
Hidden Sizes	(64, 32)
Dropout	0,1
Proporção de Validação	0,2
Batch size	64
Learning rate	0,001
Min Delta	1×10^{-4}
Epochs	10.000

Foram implementados dois critérios distintos para early stopping (*early stopping*):

- Paciência (*Patience*):** O treinamento é interrompido caso a perda de validação não apresente melhora por um período consecutivo de 100 épocas.
- Teste de Hipótese (*Teste t*):** Aplica-se um teste t de Student para avaliar a estagnação do aprendizado, configurado com uma janela de observação (*test_window*) de 60 épocas e um nível de significância (p -value) de 0,1.

Para cada estratégia de early stopping foi treinado um modelo *static*, o qual não sofre reamostragem de dados entre treino e validação para comparação. Assim foi aplicada a estratégia de validação em blocos por meio do parâmetro B , que corresponde de quantas em quantas épocas o modelo sofre a reamostragem de dados no treino. Foram testados os valores [1,5,10,20,30,50] para reamostragem. Assim, cada configuração de modelo foi testada em um conjunto de 30 seeds aleatórias.

3. TABELAS COM RESULTADOS

Na tabela 2, Os modelos com validação dinâmica apresetaram clara tendência de aumentar o número de épocas de treinamento, mas entre os modelos com mesma estratégia de parada e validação, alternando apenas o valor B , do número de blocos, não vemos uma clara tendência linear de aumento ou diminuição nas épocas. O modelo que obteve as melhores métricas foi o *h dynamic 10*, apresentando maior R^2 e menor RMSE em relação a todos os outros modelos, ainda que a variação tenha sido pequena. Nos modelos com early stopping usando paciência o modelo *patience static* foi quem teve as melhores métricas com diferença desprezível dos modelos *patience dynamic 10* e 5.

Table 2. Métricas de teste obtidas nos modelos de Regressão.

Modelo	RMSE	R^2	Épocas
h dynamic 01	$2,566 \pm 0,11$	$0,678 \pm 0,03$	$1419,9 \pm 276,7$
h dynamic 05	$2,574 \pm 0,12$	$0,676 \pm 0,03$	$1394,6 \pm 347,9$
h dynamic 10	$2,545 \pm 0,11$	$0,684 \pm 0,03$	$1408,8 \pm 364,7$
h dynamic 20	$2,584 \pm 0,14$	$0,673 \pm 0,03$	$1513,9 \pm 419,4$
h dynamic 30	$2,585 \pm 0,11$	$0,673 \pm 0,03$	$1385,6 \pm 490,6$
h dynamic 50	$2,572 \pm 0,10$	$0,677 \pm 0,03$	$1282,0 \pm 362,5$
h static	$2,608 \pm 0,12$	$0,667 \pm 0,03$	$777,1 \pm 456,5$
patience dynamic 01	$2,644 \pm 0,10$	$0,659 \pm 0,02$	$715,7 \pm 169,0$
patience dynamic 05	$2,638 \pm 0,11$	$0,660 \pm 0,03$	$795,0 \pm 216,1$
patience dynamic 10	$2,634 \pm 0,10$	$0,661 \pm 0,03$	$676,2 \pm 192,3$
patience dynamic 20	$2,657 \pm 0,09$	$0,655 \pm 0,02$	$670,9 \pm 190,0$
patience dynamic 30	$2,652 \pm 0,11$	$0,656 \pm 0,03$	$606,3 \pm 181,0$
patience dynamic 50	$2,665 \pm 0,10$	$0,653 \pm 0,03$	$647,0 \pm 203,9$
patience static	$2,600 \pm 0,13$	$0,670 \pm 0,03$	$446,9 \pm 177,2$

Na tabela 3, a tendência de mais épocas para modelos com validação dinâmica se manteve na classificação. O modelo com melhores métricas macro foi o de paciência estático, com o melhor dinâmico sendo o de paciência com reamostragem a cada 30 épocas. Nos modelo com early stopping usando teste de hipótese(h) o que teve melhores métricas foi o estático, o melhor dinâmico teve reamostragem a cada 20 épocas.

4. GRÁFICOS PRODUZIDOS

Em uma análise preliminar dos gráficos da curva de loss na validação de regressão 1 e classificação 2, percebemos que quanto menor o número de blocos, maior a tendência do modelo de criar oscilações nas curvas, causando sua subida e queda. Porém o aumento no hiperparâmetro B não significa necessariamente uma curva suave, ele aparenta causar um delay nas mudanças bruscas que ocorrem. Visto que a diferença nos picos e vales parece a mesma. Vale a pena mencionar que os gráficos afim de facilitar a visualização apresentam o resultado de somente uma seed.


5. CONCLUSÃO

Em suma, a validação dinâmica em blocos surge como uma alternativa promissora quando se opta por usar a validação dinâmica. Os modelos dinâmicos usando alguns blocos obtiveram melhores métricas que a alternativa estática por uma pequena margem. Todavia as métricas em classificação tiveram ficado favoráveis aos modelos com validação estática, os melhores modelos dinâmicos ficaram atrás por valores muito pequenos. Isso pode indicar que em cenários que compensa usar a validação dinâmica, vale a pena fazer a reamostragem por blocos buscando ajuste fino para se obter um modelo melhor.

Vale a pena mencionar que a reamostragem por blocos não se demonstrou muito eficiente para suavizar o ruído da curva de validação, visto que a variação dos picos após reamostragem se manteve

Table 3. Métricas de teste obtidas nos modelos de Classificação

Modelo	Acc	Prec	Rec	F1	Épocas
h dynamic 01	$0,681 \pm 0,01$	$0,670 \pm 0,01$	$0,632 \pm 0,01$	$0,632 \pm 0,01$	$594,7 \pm 262,0$
h dynamic 05	$0,681 \pm 0,01$	$0,670 \pm 0,01$	$0,631 \pm 0,01$	$0,631 \pm 0,01$	$915,1 \pm 509,6$
h dynamic 10	$0,685 \pm 0,01$	$0,675 \pm 0,01$	$0,636 \pm 0,01$	$0,637 \pm 0,01$	$972,5 \pm 614,2$
h dynamic 20	$0,687 \pm 0,01$	$0,678 \pm 0,01$	$0,639 \pm 0,01$	$0,640 \pm 0,01$	$577,5 \pm 414,4$
h dynamic 30	$0,686 \pm 0,01$	$0,677 \pm 0,01$	$0,637 \pm 0,01$	$0,637 \pm 0,02$	$582,8 \pm 302,2$
h dynamic 50	$0,686 \pm 0,01$	$0,676 \pm 0,01$	$0,638 \pm 0,01$	$0,640 \pm 0,01$	$690,0 \pm 542,1$
h static	$0,688 \pm 0,01$	$0,677 \pm 0,02$	$0,642 \pm 0,02$	$0,644 \pm 0,02$	$253,0 \pm 108,7$
patience dynamic 01	$0,682 \pm 0,01$	$0,670 \pm 0,01$	$0,636 \pm 0,02$	$0,637 \pm 0,02$	$295,6 \pm 116,7$
patience dynamic 05	$0,687 \pm 0,01$	$0,677 \pm 0,01$	$0,640 \pm 0,01$	$0,641 \pm 0,02$	$261,5 \pm 92,8$
patience dynamic 10	$0,687 \pm 0,01$	$0,677 \pm 0,01$	$0,640 \pm 0,01$	$0,641 \pm 0,02$	$229,5 \pm 65,5$
patience dynamic 20	$0,687 \pm 0,01$	$0,676 \pm 0,01$	$0,640 \pm 0,02$	$0,641 \pm 0,02$	$229,9 \pm 80,7$
patience dynamic 30	$0,690 \pm 0,01$	$0,681 \pm 0,02$	$0,643 \pm 0,02$	$0,645 \pm 0,02$	$235,7 \pm 102,0$
patience dynamic 50	$0,686 \pm 0,01$	$0,676 \pm 0,01$	$0,639 \pm 0,01$	$0,640 \pm 0,02$	$254,1 \pm 76,4$
patience static	$0,694 \pm 0,02$	$0,682 \pm 0,02$	$0,651 \pm 0,02$	$0,654 \pm 0,02$	$205,2 \pm 103,6$

**Figure 1.** curva loss regressão




Figure 2. curva loss classificação

parecida nos gráficos, algumas métricas de estabilidade podem estar escondendo o real valor pelo uso da média..